

변동 폭 방법론 조사

"학습 사례가 너무 일관되어 모델이 외웠다"는 진단에 대해, 합성 데이터로 검출기를 학습할 때 **변동 폭 자체**를 어떻게 넓히는지 문헌을 네 갈래로 조사하고 교차 검증했습니다. 약 80편, 인용은 초록 페이지로 확인된 것만 썼습니다.

A 도메인 무작위화

이론·절제 실험·적응형 폭. 22편

B 문서·UI 합성기

글꼴·어휘·배치 다양성, LLM 변형. 20편

C 학습 시 증강

Ultralytics 설정, 문서 검출 대회 관행. 15편

D 측정·혼합

다양성 지표, 실데이터 혼합, 평가셋 크기. 19편

1. 우리 증상은 문헌의 전형이다

연구	합성 검증	실 데이터	결론
Horváth 2022 산업 부품 검출 2208.04171	99.8	86.3 → 10.8	텍스처·후처리 변이를 빼면 실성능이 무너짐. 합성 검증은 포화
YOLOv11 합성→실 2509.15045	0.98~0.99	0.88~0.95	"합성 검증 지표는 실성능의 나쁜 예측자"
우리 4차	99.9	90.4	저확신 예측 합성 1.4% vs 실 23.9%, 실서식은 1에폭 정점


쉽게 말하면 연습 문제집으로만 채점하면 만점인 학생이 실전에서 흔들리는 것은, 문제집을 외웠기 때문입니다. 문헌은 이럴 때 "실전 시험지로 채점 기준을 바꾸고, 문제집의 변형 폭을 넓히라"고 한목소리로 말합니다.

2. 넷이 일치하는 여덟 가지

#	결론	핵심 근거	우리 상태
---	----	-------	-------

1	판정은 실서식만으로. 체크포인트 선택·조기 종료·폭 조절 모두	2208.04171 · 2509.15045 · Ultralytics best.pt는 val 기준	합성 val 사용 중
2	폭 > 사실성 > 수량. 이산 3~6값은 "풀 크기 3~6"과 같다	Tremblay 1804.06516 텍스트 풀 8K→4K -2.2 AP · Alghonaim 2011.07112 · SynthDoG 전 축 연속	이산 축
3	글꼴 가짓수가 합성기 간 가장 일관된 차이	SynthText 1,200 · SynthTIGER 3,568 · Dessurt 10,000+ · DDR 2105.14931 스타일 불일치 -6~9	3종
4	구조 문법은 옳다. 단 순수 무작위 배치는 무효	SDR 1810.10093 (25k > 무작위 200k) · DocSynth-300K 2410.12628 (Random 80.5→80.5)	카드 문법 유지
5	비대상 방해물 (도장·로고·안내문)을 필드 근처에	Eversberg 2021 0.653→0.669 · Tremblay -1.1	일부
6	어휘는 실코퍼스에서 주입. 의미의 고충실은 불필요, 분포가 덮으면 된다	Dessurt 2203.16618 · RIDGE 2504.10659 · DDR	라벨 90종
7	실데이터 소량 미세조정 이 가장 재현성 있는 처방	Nowruzi 1907.07061 실 10% ≈ 실 100% · Burdorf 2202.00632 · TFA 2003.06957	미사용
8	44장으로는 +2pt를 못 낸다. 페이지 군집 CI ±2.7~4.2pt	Field & Welsh 2007 군집 부트스트랩 · Bouthillier 2103.03098	점추정만

우리 생성기의 폭, 문헌 대비



라벨 어휘도 같습니다. 실서식 표 머리 라벨 13종 중 학습에 있는 것은 3종(23%)뿐이고, 1_corpus OCR 캐시에는 고유 한글 토큰이 4천 개 이상 있어 바로 쓸 수 있습니다.

3. 갈리는 점과 우리 판단

쟁점	한쪽	다른 쪽	판단
스캔·후처리 노이즈의 비중	A·B: 1순위 (SynthTIGER -5.2, Horváth 86→56)	C: 우리 열화 시험 99.9로 이미 포화	우리 실서식 앵커는 깨끗한 렌더라 현재 격차의 원인이 아님 . 배포용으로 유지, 우선 순위 중간

백본 동결	Tremblay: 동결하면 악화	Hinterstoisser·Ultralytics: 유사 도메인·소량이면 동결	FFDNet은 같은 문서 도메 인 48만 장 백본 → freeze 10을 1안 , 전체 미세조정 lr/10을 2안
미세조정 vs 혼합 학 습	Nowruzi: 미세조정 우세	Burdorf: 5시드 유의차 없음	둘 다 실행, 원천 분리된 실 평가로 선택
LLM이 쓰 는 HTML	DocDjinn·WebSight: 유효	WebCode2M: "깨끗하지만 단 순"으로 수렴	렌더·GT는 우리 부품 함수 가, LLM은 어휘·순서·부품 변종만 . lint 통과분만

4. 학습 설정에서 바로 고칠 것

Ultralytics 기본값 중 서식에 무의미하거나 해로운 것이 확인됐습니다. 비용 0입니다.

설정	기본	권고	이유
fliplr	0.5	0	거울상 서식은 없음. ICDAR'23 DocLayNet 1 위 팀도 제거 2305.06553
hsv_h / hsv_s	.015 / .7	0 / 0	회색조에서 색상·채도 변동은 수학적으로 무 효
mosaic · close_mosaic	1.0 · 10	0.5 · 30%	batch 4의 BN 안정성은 살리고 날칸·셀 절단 은 줄임 2004.10934 · 2406.05412
scale	0.5	(0.7, 1.6)	확대는 넓게, 축소는 8px 객체 소실 방지 2012.07177
degrees · shear · translate	0 · 0 · .1	2 · 1 · .15	학습된 검출 증강 정책의 핵심 연산 1906.11172
val · patience	합성 · 100	실서식 · 5	best.pt와 조기 종료가 실서식을 보게
freeze · optimizer	— · auto	10 · AdamW 1e-3	문서 도메인 백본 보존, neck·head만 적응

copy_paste는 폴리곤 라벨이 필요해 박스 GT로는 켤 수 없고,
label_smoothing·dropout·erasing·auto_augment는 검출에 연결돼 있지 않습니다. 골격
수준 붙여넣기는 7_augment에서 직접 구현해야 합니다.

5. 계획 P6 — 순서가 핵심

원칙은 **재는 도구 → 재는 대상 → 넓히기 → 학습 → 실데이터 혼합**입니다. 넓히기부터 하면 효과를 낼 수 없습니다.

P6-01 측정 도구. 페이지 군집 부트스트랩 CI, 에폭별 합성/실 확신도 AUROC, 백본 임베딩 coverage(클래스별). GPU 불필요.

P6-02 앵커 44→149. 원천 PDF 단위로 학습 100 / 평가 49 분할. 이것이 없으면 이후 개선을 낼 수 없고, 미세조정도 못 합니다.

P6-03 생성기 v4 "폭". 모든 테마 축 연속화, 글꼴 ≥ 30 , OCR 어휘 주입, 방해물, DPR/zoom, 배치 지터를 실서식 히스토그램에 정렬, 음성 페이지.

P6-04 학습 v4. 위 4절 설정, val=실서식, 3시드. 결과는 CI와 함께.

P6-05 실데이터 혼합. 실 100장 미세조정(head-only vs full lr/10, 합성 리플레이 20~30%) 대 혼합 학습(실 5~20% 오버샘플). 원천 분리된 49장에서 짝지은 CI로 선택.

P6-06 축 절제. 축 하나씩 켜고 끈 2k 렌더로 기여도. 예산이 남을 때.

기대 문헌 수치를 우리에게 대입하면 실 10% 미세조정만으로 실 100% 학습에 근접한 사례(Nowruz)가 있어, P6-4까지 가면 95 목표는 현실적입니다. 다만 그 판정은 CI를 붙인 149장 평가에서만 의미가 있습니다.

원문 네 보고서와 교차 검증은 저장소 6_research/variation에, 계획은 8_train/docs/PLAN.md 10절에 있습니다.