

서식 필드 검출기 1차 학습 감사

빈 한국어 행정서식 이미지에서 11종 입력칸의 위치와 종류를 찾는 검출기의 첫 학습을 데이터 구성부터 되짚는다. 합성 데이터로는 합격선을 넘었고, 실서식과 열화 스캔에서는 넘지 못했다. 이 문서는 그 격차가 어디서 오는지와 무엇을 바꿔야 하는지를 기록한다.

모델 FFDNet-L → 11클래스	입력 imgsz 1600 · batch 4	학습 20,000장 · 6 epoch · 2.6h
장비 RTX 3090 ×1 · 격리 컨테이너		

합성 홀드아웃 996장 99.97% recall@IoU0.5 · 3축 전부 통과	실서식 복제 44장 66.56% recall · 3축 전부 미달	열화 스캔 흉내 500장 55.01% recall · 3축 전부 미달
--	---	--

이 문서를 읽기 위한 용어

모델 학습을 처음 보는 사람도 뒤의 표를 읽을 수 있도록, 반복해서 나오는 말을 먼저 정리한다.

필드 · 칸	서식에서 사람이 채워 넣는 자리. 이름 쓰는 칸, 날짜 칸, 체크박스, 서명란 등. 이 프로젝트의 목표물이다.
bbox · 박스	칸을 감싸는 네모. 위치와 크기 네 숫자로 표현한다. 모델의 답은 "네모 + 종류"의 목록이다.
GT · 정답	Ground Truth. 문제집의 답안지. 여기서는 서식을 HTML로 만들 때 브라우저에게 물어 자동으로 얻는다. 손으로 라벨링하지 않는다.
클래스 · 종류	칸의 종류 11가지. text, number, date, time, phone, email, radio, checkbox, signature, textarea, image.
합성 데이터	생성기가 규칙대로 조립해 만든 가짜 서식. 정답이 공짜라 수만 장을 만들 수 있지만, 실제 서식과 미묘하게 다를 수 있다. 이 문서의 핵심 문제.
홀드아웃 · val	학습에 쓰지 않고 채점에만 쓰는 996장. 단, 같은 생성기에서 나와서 "외웠는지 이해했는지"를 완전히 가려내지는 못한다.
실서식 복제 · test	실제 행정서식 44쪽을 사람이 HTML로 충실히 옮긴 것. 학습에 안 쓴다. 진짜 실력을 재는 기준.

stress	홀드아웃 500장에 복사기·스캔 열화를 흉내 내 입힌 것. 내용은 똑같은 픽셀만 지저분하다. 픽셀 강건성을 재는 기준.
recall · 놓침	정답 칸 중 모델이 찾아낸 비율. 98%면 100칸 중 2칸을 놓친다. 못 찾은 칸을 "놓침"이라 부른다.
IoU	모델이 그린 네모와 정답 네모가 겹치는 정도. 0은 안 겹침, 1은 완전 일치. 0.5 이상이면 "위치를 맞췄다"고 본다.
유령	정답이 없는 자리에 모델이 그린 네모. 노이즈나 표 선을 칸으로 착각한 것.
종류 정확도	위치를 맞춘 칸 중 종류까지 맞춘 비율. checkbox를 radio로 답하면 위치는 맞아도 여기서 틀린다.
에폭	학습 데이터 전체를 한 번 훑는 단위. 6 에폭이면 20,000장을 여섯 번 봤다.
conf · 신뢰도	모델이 각 네모에 매기는 확신 점수. 문턱(기본 0.25) 아래는 버린다. 낮추면 더 많이 찾지만 유령도 늘다.
증강	정답은 그대로 두고 그림만 변형해 데이터를 불리는 것. 글꼴 바꾸기, 흐리게, 노이즈, 기울이기.
과적합	학습 데이터의 버릇까지 외워서 새 데이터에서 못 하는 상태. 홀드아웃 99.97%와 실서식 66.6%의 차이가 그 증거.

판정 요약

쉽게 말하면 연습 문제집(합성)은 거의 만점인데, 실전 시험(실서식)과 흐린 복사본(stress)에서는 100칸 중 각각 33칸, 45칸을 못 찾는다. 원인은 셋이다. 연습 문제가 실전보다 칸을 좁고 촘촘하게 그렸고, 지저분한 그림을 한 번도 안 보여줬고, 모양이 똑같은 두 종류(택일 □와 복수 □)는 그림만 봐서는 못 가른다.

합격선은 세 축이다. 놓침 $\text{recall@IoU0.5} \geq 98\%$, 찾은 칸 중 $\text{IoU} \geq 0.5$ 인 비율 $\geq 95\%$, 찾은 칸의 종류 정확도 $\geq 97\%$. 같은 생성기에서 나온 홀드아웃은 첫 에폭에 이미 넘겼고 다섯째 에폭에 천장을 쳤다. 그러나 실제 서식을 옮긴 44장과 홀드아웃에 열화만 입힌 500장은 세 축 모두 크게 미달이다.

격차는 성격이 다른 두 축으로 분해된다.

무엇을 바꿨나	recall	기준 대비	뜻
기준: 합성 클린 (홀드아웃)	99.97%	—	학습 분포 안에서는 문제 없음
레이아웃·치수만 다름 (실서식 복제, 픽셀 깨끗)	66.56%	-33.4pt	생성기가 만드는 칸의 치수·문맥이 실서식과 다르다
픽셀만 열화 (stress, 레이아웃 동일)	55.01%	-45.0pt	노이즈·축소·JPEG에 매우 취약하다

여기에 검출기로는 원리상 못 푸는 세 번째 문제가 있다. radio와 checkbox는 같은 □ 글리프라 문맥으로만 구분되는데, 실서식에서 radio 176개 중 106개를 checkbox로 답했고 4 에폭

을 더 돌려도 3건만 개선됐다.

즉시 착수 가능한 처방 — 픽셀 측은 7_augment 풀 62,000장으로 2차 학습(데이터·명령 준비 완료, 약 8.6시간). 레이아웃 측은 3_generator의 치수·구성 분포를 실서식 쪽으로 넓힌 뒤 재렌더. 종류 혼동은 2단계 크롭 판별. 셋은 서로 다른 격차를 겨냥하므로 병렬로 간다.

1. 학습 데이터 구성

쉽게 말하면 실제 서식 157쪽을 뜯어보고 "이런 부품이 이런 순서로 놓인다"는 규칙을 뽑은 뒤, 그 규칙으로 컴퓨터가 서식 2만 장을 새로 조립했다. 서식을 웹페이지(HTML)로 만들면 브라우저가 각 칸이 어디 있는지 정확히 알려주므로 정답이 공짜다. 이 방식의 장점은 규모이고, 약점은 "규칙에 없는 것은 절대 안 나온다"는 것이다.

데이터는 손으로 라벨링하지 않았다. 실서식을 분석해 부품과 문법을 뽑고, 그 사양으로 서식을 조립해 HTML로 만들며, 브라우저가 그린 결과에서 각 칸의 좌표를 정답으로 받는다. 단계 번호가 곧 폴더 번호다.

0 원천 사업안내 PDF 12부	1 코퍼스 실서식 85종 157쪽 PNG	2 사양 부품 79종 · 문서 문법 20 유형 · 치수 실측 분포	3 생성기 골격 JSON → HTML → Playwright PNG + GT
5 데이터셋 train 20,000 · holdout 996	7 증강 풀 62,000 + stress 500		


1.1 규모

세트	용도	페이지	박스	페이지당	출처
train	1차 학습	20,000	902,760	45.1	생성기, 시드 고정. 음성(빈) 페이지 1,323장 포함
holdout (val)	매 에폭 채점, best.pt 선택	996	45,822	46.0	생성기, 별도 시드
replica (test)	실물 격차 측정	44	954	21.7	실서식 149쪽 중 1차 44쪽을 손으로 HTML 전사
stress	픽셀 강건성 측정	500	23,681	47.4	holdout에 degraded 강도 열화

페이지당 박스 수가 이미 신호다. 합성은 45개, 실서식은 22개다. 생성기가 실서식보다 두 배 밀도로 칸을 채운다.

1.2 문서 유형 분포 (train 20,000)

문서 문법 20유형에 백지를 더한 21종. 신청서·보고서·동의서 세 유형이 39%를 차지한다.



1.3 클래스 분포 — 합성 vs 실서식

읽는 법 train %와 replica %가 크게 다른 줄이 문제다. 모델은 많이 본 종류를 잘하고 적게 본 종류를 못한다. radio는 실서식에서 다섯 칸 중 하나인데 학습에서는 스물다섯 칸 중 하나였다.

11종 클래스의 박스 점유율. 학습 분포와 실서식 분포가 어긋나는 클래스가 그대로 약점이 됐다.

class	train 박스	train %	replica 박스	replica %	차이	비고
text	306,927	34.0	313	32.8	-1.2	
number	308,970	34.2	99	10.4	-23.8	합성이 과다. 실서식에선 text→number 판별이 라벨 글자 의존
date	104,743	11.6	184	19.3	+7.7	실서식이 더 많음
checkbox	58,132	6.4	42	4.4	-2.0	
radio	40,075	4.4	176	18.4	+14.0	실서식의 ☐ 나열은 대부분 택일. 학습은 4배 과소
time	36,148	4.0	13	1.4	-2.6	
phone	17,133	1.9	30	3.1	+1.2	
signature	13,386	1.5	52	5.5	+4.0	(인)·(서명 또는 인) 문구칸
textarea	8,857	1.0	37	3.9	+2.9	stress에서 recall 1.8%로 붕괴
email	7,167	0.8	3	0.3	-0.5	표본 극소
image	1,222	0.14	5	0.5	+0.4	학습 표본 극소
합계	902,760	100	954	100		

1.4 칸의 HTML 스타일 분포 — 격차의 실체

쉽게 말하면 같은 "이름 칸"이라도 그리는 방법이 여럿이다. 표 한 칸을 통째로 쓰는 방식, 표 칸 안에 여백을 두는 방식, 문장 사이에 눈에 안 보이는 빈자리를 두는 방식, 밑줄 방식, ☐ 표시 방식. 생성기는 첫 번째 방식을 압도적으로 많이 썼는데 실제 서식은 그 방식을 거의 안 쓴다. 그리고 실제 서식의 빈칸은 생성기가 만든 것보다 두세 배 넓거나 높다. 모델은 "좁은 빈칸"만 배웠기 때문에 넓은 빈칸을 못 알아본다.

같은 클래스라도 HTML에서 칸을 그리는 방식이 다르다. 표 셀을 통째로 채우는 `cg`, 셀 안쪽 여백을 둔 `cgf`, 문장 속 투명 빈칸 `gp`, 밑줄 `u1`, ☐ 마커. 생성기 출력과 실서식 복제의 구성 비율이 크게 다르다.

스타일	모양	홀드아웃 100장	%	replica 44장	%	replica recall
cg	표 셀 전체 채움	4,242	77.0	51	5.3	1.96%
cgf	셀 안쪽 여백 있는 채움	237	4.3	269	28.2	58.7%
gp	문장 속 투명 빈칸 (표시 없음)	319	5.8	187	19.6	56.2%
(none)	클래스 없는 data-f 요소	674	12.2	223	23.4	64.1%
ul	밑줄	27	0.5	25	2.6	96.0%
ck · mk · db · br	□ 마커, 도장 박스 등 (생성기에 없음)	0	0	162	17.0	98~100%
dbx · mkc · opt · circ	이중 박스, 척도 칸, 원형 마커 (생성기에 없음)	0	0	33	3.5	0~63%
합계		5,508	100	954	100	66.6%

홀드아웃 100장은 스타일 불문 recall 100%. replica 수치는 6 에폭 best.pt, conf 0.25.

두 가지가 눈에 띈다. 생성기 GT의 77%를 차지하는 주력 스타일 cg 가 실서식에서는 5%뿐이고, 그 51개 중 1개만 잡혔다. 반대로 생성기에 아예 없던 마커·도장 박스는 95~100%로 잘 잡힌다. 모델은 처음 보는 구성을 못 찾는 게 아니라, *아는 구성인데 치수와 문맥이 다른 것*을 못 찾는다.

같은 스타일의 박스 치수 (중앙값, px)	replica w × h	홀드아웃 w × h	어긋남
gp 투명 빈칸	100.0 × 18.4	40.0 × 19.5	폭 2.5배. 학습은 "짧은 빈칸"만 봤다
cgf 셀 채움(여백)	154.0 × 40.6	281.5 × 25.8	높이 1.6배. 실서식은 다행 셀
cg 셀 채움(전체)	181.8 × 26.0	118.1 × 26.0	폭 1.5배

1.5 증강 풀 (7_augment)

쉽게 말하면 깨끗한 서식 2만 장을 복사기로 여러 번 복사한 것처럼 만들어 6만 장으로 불렀다. 글꼴을 바꾼 것, 사무실 복사 품질로 조금 흐린 것, 낡은 팩스처럼 많이 망가진 것. 1차 학습에는 이걸 안 썼고, 그래서 흐린 그림에 약하다.

1차 학습에는 쓰지 않았다. 골격은 조판, 증강은 획득 과정이라는 계약을 지켜 라벨은 건드리지 않고 픽셀만 바꾼다. 기하 변형은 YOLO 온라인 증강에 맡긴다.

구분	장수	원천	강도	용도
clean	20,000	5_dataset/train	없음	1차 학습
swap	6,000	골격 재렌더	서체만 (나눔고딕 / 나눔명조)	2차
office	20,000	clean × 1	사무 스캔: dpi .70~1.0, 경사 ≤10%, JPEG 70~92, 잉크 30%	2차
office_swap	6,000	swap × 1	//	2차
degraded	8,000	clean 표본	열화: dpi .55~.85, 경사 ≤28%, JPEG 35~65, 노이즈 σ4~10, 잉크 70%	2차
degraded_swap	2,000	swap 표본	//	2차
학습 합계	62,000	클린계 26k (42%) · 사무 26k (42%) · 열화 10k (16%) · 총 9.4GB		
stress	500	holdout 표본	열화	평가 전용

서버에서 재생성한 렌더는 Mac 원본과 바이트 동일하지 않다. 요소 개수·타입 100% 일치, 좌표 최대 1.58px, 픽셀 0.8~1.1% 차이. Chromium 래스터화 차이이며 라벨-픽셀 정합은 렌더 내부에서 완결되므로 학습에 무해하다.

2. 학습 설정

쉽게 말하면 처음부터 가르치지 않고, 이미 PDF 서식의 입력칸을 찾도록 배운 모델(FFDNet)을 데려와 우리 11종으로 다시 가르쳤다. 시작점이 좋아서 첫 에폭에 이미 합성 기준을 넘겼다. 그림은 긴 변 1600픽셀로 넣는데, 22픽셀짜리 작은 □가 사라지지 않게 하기 위해서다. GPU 한 장 기준 한 번에 4장씩만 볼 수 있었다.

항목	값	근거
출발 가중치	FFDNet-L (YOLO11, 25.3M, 3클래스 → 11클래스 헤드 교체)	CommonForms 논문. PDF 서식 입력칸 검출기라 같은 문제. 가중치 1,015개 전부 이전
입력 크기	imgsz 1600	페이지 94%가 1004×1400이라 축소 없음. 22px 마커가 최악 12px 유지
batch	4	8은 CUDA OOM. 3090 24GB + 1600px의 상한. GPU 21.7GB · util 83%
증강	FFDNet 레시피 + fliplr=0	좌우 반전은 라벨 글자를 뒤집어 종류 판별을 해침
최적화	MuSGD lr0 0.01 · patience 100	Ultralytics 자동. patience가 커서 조기 종료가 사실상 꺼져 있었음
에폭	60 계획 → 6에서 수동 중단	val 포화 + 실물 지표 정체. 에폭당 28.1분, 누적 158.6분
데이터 정의	forms.yaml (clean 20,000만)	2차는 forms_aug.yaml (62,000)

3. 평가 결과

쉽게 말하면 세 가지 시험을 봤다. 연습 문제집에서 뽑은 996장, 실전 44장, 흐린 복사본 500장. 채점은 세 항목이다. 칸을 찾았나(놓침), 찾은 칸의 위치가 정확한가(좌표), 종류를 맞췄나(종류). 연습 문제집은 전부 통과, 나머지 둘은 전부 미달이다.

3.1 에폭별 홀드아웃 지표

epoch	precision	recall	mAP50	mAP50-95	box loss	cls loss
1	0.981	0.987	0.993	0.844	0.786	0.818
2	—	0.994	—	0.857	—	0.412
3	—	0.996	—	0.852	—	—
4	—	0.997	—	0.869	—	—
5	0.994	1.000	0.995	0.876	0.695	0.376
6	0.992	0.999	0.995	0.876	0.686	0.364

recall은 1 에폭에 합격선을 넘고 5 에폭에 천장. mAP50-95는 6 에폭에 +0.011pt로 평평. 빈칸은 정기 보고에 포함되지 않은 값.

3.2 세 축 최종 채점 (6 에폭 best.pt, conf 0.25)

매칭은 클래스 무관 Hungarian(IoU 0.10 이상)으로 하고 종류는 매칭 후 따로 센다. 위치는 맞고 종류만 틀린 칸이 놓침으로 잘못 집계되지 않게 하기 위해서다.



세트	GT	예측	놓침	유령	판정
홀드아웃	45,822	46,080	3	261	3축 통과
실서식 복제	954	963	253	262	3축 미달
stress	23,681	33,940	8,287	18,546	3축 미달 예측이 GT의 1.43배

3.3 실서식 44장의 에폭별 추세

epoch	recall	좌표	종류	놓침	유령	radio→checkbox	text 놓침
1	65.93	89.22	60.57	249	248	106	94
5	63.10	88.92	63.81	277	152	103	103
6	66.56	90.58	61.06	253	262	106	95

홀드아웃이 98.7 → 99.97로 오르는 동안 실서식은 63~67 사이에서 흔들렸다. 954칸에서 3pt는 박스 27개라 노이즈 범위 안이다. 학습을 더 돌려도 실물이 좋아지지 않는다는 뜻.

3.4 클래스별 · 실서식 복제 44 (1 에폭 스냅샷)

1 에폭 시점의 클래스별 상세. 6 에폭과 전체 recall이 거의 같아(65.9 vs 66.6) 경향은 그대로 다.

class	GT	recall	종류 정확	주된 오답
checkbox	42	100.0	95.2	—
signature	52	82.7	65.9	text로 11건
radio	176	76.7	21.5	checkbox로 106건
textarea	37	67.6	60.7	text로 10건
email	3	66.7	0.0	표본 3
text	313	63.3	76.7	놓침 94, number 15, date 14, email 12
image	5	60.0	40.0	radio로 3건
date	184	59.2	87.8	놓침 37, radio 9
phone	30	56.7	27.3	text로 16건
number	99	49.5	12.7	text로 42건, 놓침 44
time	13	46.2	0.0	date로 4건

종류 정확은 위치를 맞춘 칸 중 비율. 모양이 같고 옆 글자로만 구분되는 radio·number·phone·time이 무너진다.

읽는 법 checkbox는 100% 찾고 95% 종류도 맞춘다. 그런데 radio는 77%를 찾기도 종류는 21%만 맞춘다. 둘 다 같은 □ 그림이라, 모델은 □를 보면 그냥 checkbox라고 답한다. "하나만 고르시오"라는 문맥은 그림에 없다.

3.5 클래스별 · stress 500

class	GT	recall	매칭 중 종류 정확	읽기
checkbox	1,357	84.8	94.7	열화에도 마커는 버팀
image	34	76.5	—	
radio	951	58.7	90.3	
time	993	55.9	—	
number	8,713	54.3	—	
text	7,915	53.8	95.9	찾기만 하면 종류는 맞춤
date	2,626	52.7	—	
email	168	47.0	—	
phone	378	42.1	—	
signature	325	39.4	87.0	
textarea	221	1.8	—	큰 영역 박스가 축소·노이즈에 붕괴. 홀드아웃 mAP50 0.995

stress의 실패는 종류 판별(76.5%)이 아니라 검출 자체다. 유령 18,546개는 노이즈·줄무늬를 필드로 오인한 것.

3.6 실서식 페이지별 — 최악과 최선

최악 5장	GT	recall
2편 서식17호 지정(변경) 신청서-2	2	0.0
1편 서식17호 이용자 만족도 질문지-1	47	25.5
1편 서식6호 장애아돌보미 선발·심사 기준-1	26	30.8
2편 서식13호 경력 조회 동의서-1	15	33.3
2편 서식16호 제공기관 지정 공모-1	14	35.7

최선 3장	recall
2편 서식21호 제공기관 지정서-1	94.1
1편 서식1_2호 개인정보 동의서(이용자)-1	92.9
1편 서식3호 개인정보 동의서-1	91.7

만족도 질문지와 심사 기준표는 척도 칸(opt)과 빈 셀이 반복되는 구성이라 생성기에 없다. 동의서·지정서처럼 표와 밑줄 위주 서식은 잘 된다.

4. 격차 진단

쉽게 말하면 "왜 실전에서 못 찾나"에 대한 흔한 답 세 가지를 하나씩 확인해서 지웠다. 문턱이 너무 높아서? 아니다, 문턱을 다 내려도 71%에서 멈춘다. 정답 표기 방식이 달라서? 아니다, 놓친 칸 96%는 그 자리에 아무것도 안 그렸다. 처음 보는 모양이라서? 아니다, 처음 보는 □와 도장칸은 잘 찾는다. 남은 답은 "아는 모양인데 크기가 달라서"와 "그림이 지저분해서"다.

실서식 66%의 원인 후보를 하나씩 기각했다. 전부 CPU로 돌렸고 학습에 영향은 없었다.

4.1 신뢰도 문턱인가 — 아니다

conf	예측	recall	유령	종류 정확	놓침
0.05	1,183	71.38	417	62.27	188
0.10	1,020	69.08	277	62.45	211
0.25	829	63.10	152	63.81	277

5 에폭 스냅샷. 문턱을 5%까지 내려도 71%에서 천장. 유령만 2.7배.

4.2 라벨 규약 불일치인가 — 아니다

놓친 277칸을 예측과 겹침으로 분류했다. 실서식 GT와 생성기 GT의 규약이 어긋났다면 GT 하나를 예측 여럿이 쪼개거나 예측 하나가 GT를 삼키는 패턴이 나와야 한다.

놓침 277 원인	건	%	유령 152 원인	건	%
겹치는 예측 없음 (진짜 미검출)	267	96.4	GT와 무접촉 (순수 유령)	111	73.0
부분 겹침	9	3.2	GT 안에 들어감 (중복 검출)	30	19.7
쪼개짐 (예측 2개 이상)	1	0.4	GT와 부분 겹침	11	7.2
삼킴 (예측이 GT 포함)	0	0.0			

규약 문제는 1건이다. 모델은 그 자리에 아무것도 그리지 않는다. 놓침의 크기 분포는 중간 192(69%), 작음 58(21%), 넓음 27(10%)로 작은 박스만의 문제가 아니라 해상도를 더 올려도 안 풀린다.

4.3 처음 보는 구성이라서인가 — 아니다

1.4절의 스타일별 표가 답이다. 생성기에 없던 마커·도장 박스는 98~100%로 잡히고, 생성기의 주력인 cg·cgf·gp가 무너진다. 같은 부품인데 치수와 문맥이 다른 것이 원인이다. 놓친 40칸

을 잘라 모은 그림에서 반복되는 것은 문장 속 ○○○ 빈칸, 라벨만 있고 비어 있는 표 셀, (인) 도장칸, am/pm 칸, 만족도 척도 칸이다.

4.4 픽셀 강건성 — 가장 큰 축

stress 500은 홀드아웃과 *내용·레이아웃이 완전히 같고* dpi 축소, JPEG, 노이즈, 잉크 침식, 경사만 다르다. 그런데 recall이 100%에서 55%로 떨어진다. 이 축은 실서식 축(-33pt)보다 크고, 이미 62,000장 풀이 준비돼 있어 즉시 착수 가능하다.

1차 학습 중 이 문서의 이전 판단은 두 번 뒤집혔다. 1 에폭 때는 "학습 부족"으로, 스타일 진단 후에는 "픽셀 증강 대상 아님"으로 봤다. stress 수치가 나오고서야 두 축이 모두 실재하고 픽셀 축이 더 크다는 것이 확정됐다. 홀드아웃만 보고 판단한 것이 근본 원인이며, 5절 8항의 프로세스 처방으로 이어진다.

4.5 판단 이력

이 결론에 이르기까지 판단이 어떻게 바뀌었는지 남긴다. 다음 학습에서 같은 함정을 피하기 위해서다.

- 계획
60 에폭, 2×3090 . 합성 홀드아웃 지표로 진행 판단.
- 1 에폭 (28분)
홀드아웃 recall 98.7%로 합격선 통과. 실서식은 65.9%. 이때는 "아직 덜 배워서"로 봤다.
- 5 에폭
홀드아웃 99.97% 천장. 실서식 63.1%로 오히려 하락, radio→checkbox 106→103건. "덜 배워서"를 철회하고 합성 과적합으로 판단. 중단 규칙을 10 에폭으로 정함.
- 진단 A~C
문턱·라벨 규약·미검출 여부 확인. 진짜 미검출 96.4%.
- 진단 F
스타일별 recall. 생성기 주력 cg가 1.96%, 처음 보는 마커는 98~100%. "치수·문맥 분포 밖"으로 확정. 이때 "픽셀 증강은 무관"으로 잘못 일반화했다.
- 6 에폭 중단
mAP50-95 +0.011pt로 평평. 사용자 결정으로 종료.
- stress 채점
55.0%. 픽셀 축이 실재하고 더 크다는 것이 확정. 두 축 병행으로 결론.

5. 피드백과 처방

쉽게 말하면 세 가지를 동시에 한다. 흐린 복사본 6만 장으로 이어서 가르친다(준비 끝, 8시간). 연습 문제 생성기가 실제 서식처럼 넓은 칸과 빈 칸, 도장칸을 더 만들게 고친다. □가 택일인지 복수인지는 그림만으로 못 가르니, 찾은 뒤 주변을 읽어 종류를 정하는 두 번째 단계를 붙인다.

우선순위 순. 앞의 셋은 서로 다른 격차를 겨냥하므로 병렬로 진행한다.

1

2차 학습: 증강 풀 62,000장으로 이어서 학습 픽셀 축 · 준비 완료

1차 best.pt에서 출발, 6 에폭(약 8.6시간), patience 3. 중단 규칙은 stress recall이 2 에폭 연속 +1pt 미만. 에폭마다 stress 500과 실서식 44를 CPU로 채점해 홀드아웃만 보는 실수를 반복하지 않는다. 기대 효과는 stress 축 회복과 유령 18,546개의 감소.

2

생성기 치수·구성 분포를 실서식 쪽으로 레이아웃 축 · 3_generator

- 3 gp 투명 빈칸 폭 범위를 40px 고정 근처에서 40~200px로. 문장 속 ○○○, "총 ○○시간" 형태의 prefill 빈칸 추가.
- 4 cgf 높이를 26px 단일에서 26~60px 다행 셀까지. 라벨만 있고 비어 있는 셀 비중 상향.
- 5 cg 셀 채움의 점유율 77%를 낮추고 cgf·gp·(none)을 실서식 비율 (28·20·23%)에 근접시킨다.
- 6 실서식에만 있는 구성 추가: (인)·(서명 또는 인) 도장칸, am/pm 칸, 만족도 척도표(opt), 원형 마커(circ), 이중 박스(dbx).
- 7 검증은 `diag_style.py --compare` 로 스타일별 recall 전후 비교. 페이지당 박스 밀도도 45개에서 실서식 22개 쪽으로 분산.

8

종류 혼동은 검출기 밖에서 2단계 · 8_train 예정안

radio→checkbox 106건과 number→text 42~52건은 모양이 같고 라벨 글자·그룹 문맥으로만 갈리는 축이다. 먼저 후처리 규칙(같은 행·같은 셀에 □가 2개 이상이면 radio)으로 얼마나 줄어드는지 재고, 남는 것을 검출 박스 주변 크롭으로 Qwen3-VL에 11종 중 하나만 고르게 한다. 좌표 생성이 없으니 유령이 없다.

9

클래스 불균형 보정 3_generator 쿼터

image 0.14%, email 0.8%, textarea 1.0%는 두 자릿수 적다. radio는 실서식 18.4% 대비 4.4%로 4배 과소, number는 34.2% 대비 10.4%로 3배 과다. QUOTA를 실서식 비율로 재 조정하거나 손실 가중치를 둔다.

10

평가 앵커 확장 4_replica 44 → 149

44장 954칸에서 3pt는 박스 27개라 예폭별 추세를 읽기엔 거칠다. 대기 중인 105쪽(표준·밀집 28·초밀집 13)을 전사하면 실물 기준이 안정된다. 보고에는 부트스트랩 95% CI를 붙인다.

11

stress 유령 억제 7_augment

음성 페이지 1,323장에도 열화를 입힌 hard negative가 풀에 포함되는지 확인한다. 열화된 빈 페이지에서 아무것도 그리지 않는 예가 있어야 노이즈를 필드로 오인하는 습관이 꺾인다. 후처리로 최소 변 길이 필터와 IoU 0.5 NMS를 둔다.

12

textarea 붕괴 별도 추적 stress 1.8%

큰 영역 박스가 dpi 축소에 특히 약하다. 2차 후에도 안 오르면 degraded 구간의 축소 하한 (0.55)을 재검토하거나 textarea 표본을 늘린다.

13

프로세스: 실물 지표로 1차 지표로 운영

홀드아웃은 같은 생성기 출력이라 항상 낙관적이다. 앞으로 모든 학습은 예폭마다 실서식 44와 stress 500을 채점하고 그 추세로 종단을 판단한다. 이번에 확인된 함정도 기록해 둔다: Ultralytics project 상대경로는 엉뚱한 곳에 저장하며, 3090 한 장에서 1600px는 batch 4가 상한이고, 학습 중 GPU 채점은 OOM으로 본론을 죽인다.

부록 · 재현과 산출물

재현 순서 (컨테이너 /work)

```
python 8_train/to_yolo.py                                # 5_dataset → 8_train/yolo +
forms.yaml
python 7_augment/render_swap.py --n 6000 > 7_augment/render_swap.log
./7_augment/build_pool.sh                                # 풀 62,000 + stress 500, 마지막 줄
BUILD_DONE
python -c "from huggingface_hub import hf_hub_download as d; d('jbarrow/FFDNet-L','FFDNet-
L.pt',local_dir='8_train/weights')"
```

1차 (실행한 그대로)

```
yolo detect train model=8_train/weights/FFDNet-L.pt data=/work/8_train/yolo/forms.yaml \
  imgs=1600 epochs=60 batch=4 device=0 flipplr=0 project=/work/8_train/runs name=ffdnet_1600
```

```
# 2차 (준비 완료, 미실행)
yolo detect train model=/work/8_train/runs/ffdnet_1600/weights/best.pt
data=/work/8_train/forms_aug.yaml \
  imgs=1600 epochs=6 batch=4 device=0 fliplr=0 patience=3 project=/work/8_train/runs
name=ffdnet_1600_aug

# 채점 3축 + 진단
python 8_train/score.py --model <best.pt> --images 8_train/yolo/images/replica --labels
8_train/yolo/labels/replica --name test
python 8_train/diag_replica.py --model <best.pt> --images ... --labels ... --device cpu
python 8_train/diag_style.py --model <best.pt> --html-dir 4_replica/html --images ... --labels
... --out style.json
```

도구

파일	역할
8_train/score.py	README 3축 채점. 클래스 무관 Hungarian 매칭, 11×11 confusion, --selftest
8_train/diag_replica.py	농침·유령 해부: 진짜 미검출 vs 쪼개짐·삼킴·부분겹침, 크기·클래스 분포
8_train/diag_style.py	HTML 스타일별 recall과 치수 중앙값, --compare 로 전후 비교
8_train/forms_aug.yaml	2차 데이터 정의 (train 62,000 · val 996 · test 44+500)
docker/	격리 학습 컨테이너 (GPU 1장 고정, 48GB, 포트 없음, Claude Code Remote Control)

산출물 (서버)

- 8_train/runs/ffdnet_1600/ — weights/best.pt · last.pt (152MB), results.csv
- 8_train/runs/score/{val,test,stress}.json — 3축 채점, 페이지별 수치
- 8_train/runs/val/{uval,utest,ustress}/ — Ultralytics 표준 채점, confusion_matrix.png
- 8_train/runs/preview/ — 사고보고서 예측 오버레이, 농침 필드 40개 contact sheet

본 문서의 수치는 2026-09-08 컨테이너 세션 보고와 저장소 README를 근거로 한다. 실서식 44장의 클래스별 세부와 confusion 원자료는 score/test.json에 있다.