

서식 필드 검출기 2차 학습 보고

1차 학습이 남긴 두 격차 가운데 더 큰 쪽, 픽셀 열화 축을 겨냥한다. 같은 모델을 깨끗한 서식 대신 복사기·스캔 품질로 망가뜨린 서식 62,000장으로 이어서 가르친다. 이 문서는 1차와 무엇이 다른지, 무엇을 기대하고 무엇을 기대하지 않는지, 어떻게 재는지를 먼저 적고, 에폭별 결과를 이어서 채운다.

출발점 1차 best.pt (6 epoch)	데이터 62,000장 · 6구분	학습 1 epoch · 79분 (6 계획)
상태 R1 달성 종료 · last_e1.pt		

stress 500 · 55.01 → 99.94% recall · 3축 전부 통과 1 에폭	실서식 44 · 66.56 → 59.64% recall · 미달 · 7pt 악화	홀드아웃 996 · 99.97 → 100.0% recall · 유지
--	--	---

요약

결과 한 줄 망가진 서식 6만 2천 장을 한 번 훑는 것(79분)만으로 흐린 복사본 시험이 55점에서 99.9점이 됐다. 그러나 실전 서식은 67점에서 60점으로 내려갔다. 지저분한 그림에 맞추면서 실제 서식의 넓은 칸을 더 못 보게 된 것이다. 픽셀 문제는 끝났고, 남은 것은 생성기가 만드는 칸의 치수다.

배경 1차 모델은 깨끗한 서식만 보고 자라서 흐린 복사본을 보면 노이즈를 칸으로 착각하고(유령 18,546개) 진짜 칸은 못 찾는다(45%가 사라짐). 2차는 같은 모델에게 일부러 망가뜨린 서식을 4만 장 더 보여줘서 "지저분해도 칸은 칸"이라는 걸 가르친다. 다만 실제 서식이 연습 문제보다 칸을 넓게 그린다는 문제는 이 학습으로 안 풀린다. 그건 생성기를 고쳐야 한다.

격차	1차 기준선	2차가 겨 냥하나	근거
픽셀 열화 (stress)	55.01%	예 주 목표	결과 99.94%. 학습 풀에 같은 종류의 열화를 넣으니 1 에폭에 닫혔다
레이아웃·치수 (실서식)	66.56%	아니오	결과 59.64%, 악화. 픽셀 증강은 치수 분포를 바꾸지 않고, 열화에 맞추면서 셀 채움 칸(cgf)을 21.9pt 더 못 잡게 됐다. 두 축은 독립이 아니라 일부 상충한다
radio ↔ checkbox 혼동	106 / 176	아니오	변화 없음. 같은 □ 클리프. 2단계 판별의 뒀

1. 1차와 무엇이 다른가

항목	1차	2차	왜 바꿨나
출발 가중치	FFDNet-L (3클래스 → 11 클래스 헤드 교체)	1차 best.pt (이미 11클래스, 1,015개 전부 이전)	깨끗한 분포는 이미 배웠다. 새로 배울 것 은 열화와 서체뿐
학습 데이터	clean 20,000	clean 20,000 + swap 6,000 + office 26,000 + degraded 10,000 = 62,000	열화 데이터가 없어서 stress에서 무너졌 다
에폭당 반복	5,000	15,500	데이터 3.1배
에폭당 시간	28분	약 86분	같은 속도(초당 3.0 반복)
에폭 수	60 계획, 6에서 수동 중단	6 계획, 지표로 조기 종료	1차는 5 에폭에 포화했다. 6 에폭이면 93,000 반복으로 1차 포화점의 3.7배
patience	100 (사실상 꺼짐)	3	홀드아웃 기준 조기 종료가 실제로 동작 하게
진행 판단 지표	홀드아웃만	stress 500 + 실서식 44를 에폭마다 CPU로 채점	1차에서 홀드아웃만 보다가 실물 격차를 5 에폭까지 몰랐다
중단 규칙	mAP50-95 상승폭 (나중 에 폐기)	stress recall이 2 에폭 연속 +1pt 미만이면 중단	목표 축을 직접 본다
학습률	lr0 0.01 자동	동일	분포를 크게 옮기는 것이 목적이라 기본 값 유지
batch · imgsz · fliplr	4 · 1600 · 0	동일	비교 가능성

2. 학습 데이터 62,000장

쉽게 말하면 깨끗한 원본 2만 장은 그대로 두고, 같은 서식을 글꼴만 바꿔 다시 그린 것 6천 장, 사무실 복사기 품질로 살짝 흐린 것 2만 6천 장, 낡은 팩스처럼 많이 망가진 것 1만 장을 더했다. 정답 좌표는 하나도 바뀌지 않는다. 그림만 지저분해진다.

구분	장수	비율	원천	무엇을 바꾸나
clean	20,000	32%	5_dataset/train	없음. 1차와 동일 (Mac 렌더)
swap	6,000	10%	골격 재렌더 (컨테이너)	서체만: 함초롬·명조 → 나눔고딕 / 나눔명조
office	20,000	32%	clean ×1	dpi 0.70~1.0 축소, 밝기·대비·조명 경사 ≤10%, JPEG 70~92, 가우시안 0~3, 줄무늬 15%, 잉크 팽창·침식 30%
office_swap	6,000	10%	swap ×1	//
degraded	8,000	13%	clean 표본	dpi 0.55~0.85, 경사 ≤28%, JPEG 35~65, 가우시안 4~10, 줄무늬 50%, 먼지, 잉크 70%, 블러 0.5~1.2
degraded_swap	2,000	3%	swap 표본	//
합계	62,000	100%	클린계 42% · 사무 42% · 열화 16%. 모든 구분에 러닝헤드·쪽번호·챗터탭 등 지면 맥락을 여백에 무작위로 없음	

기하 변형(회전 1°, 원근, 이동, 스케일)은 YOLO의 온라인 증강이 학습 중에 따로 건다. 좌우 반전은 라벨 글자를 뒤집으므로 끈다.

stress 500은 degraded와 같은 강도로 홀드아웃을 열화한 것이다. 즉 2차 학습 풀의 열화와 stress의 열화는 같은 생성기에서 나왔다. 이 점은 결과 해석에서 유의해야 한다. stress가 회복되면 "이 종류의 열화에 강해졌다"이지 "모든 스캔에 강해졌다"는 아니다. 실제 스캔본 평가는 별도 과제다.

3. 측정 설계

세트	장수	언제	어디서	무엇을 보나
홀드아웃 (val)	996	매 에폭, 학습이 자동	GPU	best.pt 선택 기준. 99.97%가 유지되는지 (열화를 배우느라 깨끗한 것을 잊지 않는지)
stress	500	매 에폭 종료 직후	CPU 8.7분, 9.2GB	주 지표. recall과 유령 수. 중단 규칙의 근거
실서식 복제	44	매 에폭 종료 직후	CPU 72초	레이아웃 축이 부수적으로 움직이는지. 크게 기대하지 않음

세 세트 모두 클래스 무관 Hungarian 매칭으로 놓침·좌표·종류 세 축을 낸다(score.py). 표본 50장 방식은 오차가 ±13pt라 기각했고, 500장 전량을 CPU로 돌린다. 학습 중 GPU를 채점에 쓰면 메모리 부족으로 본런이 죽는 것을 1차에서 확인했다.

중단 규칙

- stress recall이 2 에폭 연속 직전 대비 +1pt 미만이면 멈춘다.
- 홀드아웃 기준 patience 3. 홀드아웃이 3 에폭 연속 안 오르면 Ultralytics가 멈춘다.


- 어느 쪽이든 best.pt와 last.pt를 보존하고 세 세트 최종 채점을 GPU로 돌린다.

4. 기준선 — 1차 종료 시점

2차의 모든 숫자는 이 표와 비교한다.

세트	recall@0.5	좌표 IoU≥0.5	종류 정확	놓침	유령
홀드아웃 996	99.97	99.98	99.95	3	261
실서식 44	66.56	90.58	61.06	253	262
stress 500	55.01	84.62	76.48	8,287	18,546

stress 클래스별 recall (기준선)



stress에서는 찾기만 하면 종류는 잘 맞춘다(76%). 실패는 검출 자체다. 유령 18,546개는 예측 총수를 정답의 1.43배로 만든다. 노이즈와 줄무늬를 칸으로 오인한 것이다. textarea 1.8%는 큰 영역 박스가 축소와 노이즈에 특히 약하다는 뜻이며 별도로 추적한다.

5. 기대와 한계

기대하는 것

- stress recall 55% → 대폭 상승. 학습 풀의 열화와 같은 종류이므로 홀드아웃(99.97%)에 근접할 수 있다.
- stress 유령 18,546개 → 크게 감소. "빈 페이지 열화 본에서 아무것도 안 그리기"를 배운다.
- textarea·signature 같은 큰 영역 박스의 회복.

기대하지 않는 것

- 실서식 44장의 큰 개선. 칸의 치수·문맥 분포는 그대로다. 서체 스왑으로 1~3pt 정도 흔들릴 수 있다.
- radio ↔ checkbox 혼동 해소. 그림에 정보가 없다.
- 실제 스캔본 일반화의 증명. stress는 우리 생성기의 열화다.

- 홀드아웃 99.97% 유지. clean 20,000장이 풀에 그대로 있어 망각 위험은 낮다.

결과를 읽는 기준 stress가 90% 위로 오르고 홀드아웃이 99% 위에 머물면 픽셀 축은 닫힌 것이다. stress가 70% 근처에서 멈추면 열화 강도나 구성이 부족한 것이고, 홀드아웃이 떨어지면 clean 비중을 올려야 한다. 실서식이 그대로면 예상대로이고, 다음은 생성기 치수 분포 확장이다.

6. 결과


쉽게 말하면 첫 에폭이 끝나자 규칙 R1(흐린 복사본 95점 이상, 연습 문제집 99.5점 이상)이 걸려 자동으로 멈췄다. 계획한 6 에폭 중 1 에폭, 8시간 중 79분만 썼다. 흐린 복사본은 사실상 만점이 됐고, 큰 영역 칸(textarea)은 1%에서 100%로 살아났다. 그런데 실전 서식은 7점 떨어졌다. 문턱을 낮춰 봐도 똑같이 7점 차이가 나므로 "조심스러워져서"가 아니라 "특정 칸을 아예 안 그리게 된" 것이다.

6.1 에폭별 추세

epoch	val recall	val mAP50-95	stress recall	stress 유형	stress 종류	실서식 recall	실
0 (1차 e6)	99.97	0.876	55.01	18,546	76.48	66.56	
1	100.00	0.889	99.94	369	99.93	59.64	

에폭별 채점은 last.pt 기준. 종료 후 last_e1.pt를 최종 가중치로 지정.

6.2 최종 3축 채점 (last_e1.pt, conf 0.25)



세트	GT	농침	유령	1차 대비	판정
홀드아웃	45,822	1	488	농침 3→1, 유령 261→488	3축 통과
stress	23,681	7	369	농침 8,287→7, 유령 18,546→369	3축 통과
실서식 복제	954	340	206	농침 253→340, 유령 262→206	3축 미달

Ultralytics 표준 지표로도 같다. stress는 P 0.626 → 0.988, R 0.395 → 0.999, mAP50 0.415 → 0.995이고 11개 클래스 전부 R ≥ 0.994다. textarea는 R 0.009 → 1.000.

6.3 실서식 하락은 보수화가 아니다 — 신뢰도 스윙

conf	1차 e6 recall	2차 e1 recall	Δ	1차 유령	2차 유령	1차 종류	2차 종류
0.05	72.54	65.62	-6.92	541	419	59.51	64.65
0.10	70.13	63.21	-6.92	420	327	60.13	64.70
0.25	66.56	59.64	-6.92	262	206	61.06	64.82

세 문턱에서 정확히 같은 -6.92pt. 문턱 문제라면 낮출수록 격차가 줄어야 한다. 2차 모델은 어떤 문턱에서도 특정 칸을 그리지 않는다. 종류 정확도는 전 구간에서 3~5pt 높다.

6.4 어떤 칸을 잃었나 — 스타일별 전후 비교

HTML 스타일	GT	1차 e6	2차 e1	Δ	치수 w×h	읽기
cgf 셀 채움(여백)	269	66.91	44.98	-21.93	154×41	실서식의 다행 셀. 생성기는 26px 단일 높이
dbx 이중 박스	16	75.00	56.25	-18.75	66×27	생성기에 없음
cg 셀 채움(전체)	51	7.84	1.96	-5.88	182×26	생성기 주력 스타일인데 실서식 폭이 1.5배
ul 밑줄	25	92.00	88.00	-4.00	100×16	
gp 투명 빈칸	187	54.55	53.48	-1.07	100×18	그대로 나뉨
(none)	223	66.37	66.37	0	30×19	
ck 마커	105	99.05	99.05	0	22×22	
mk · db · br · ulx · grey	62	100	100	0	—	
mkc	4	50.00	75.00	+25.0	22×22	표본 4
stamp 도장칸	1	0	100	+100	118×118	표본 1
opt · circ 척도 · 원형	13	0	0	0	22~26	생성기에 없음, 여전히 0
합계	954	66.56	59.64	-6.92		

손실이 셀 채움 계열(cgf·cg)과 이중 박스에 몰려 있다. 마커류와 소형 요소는 그대로거나 좋아졌다. 열화에 맞추면서 실서식의 넓고 높은 칸을 더 못 잡게 됐다.

쉽게 말하면 모델이 잃은 것은 "표 한 칸을 통째로 쓰는 넓은 빈칸"이다. 생성기가 만든 그런 칸은 높이 26px인데 실제 서식은 41px이고, 지저분한 그림에서 26px짜리를 찾는 연습을 하고 나니 41px짜리는 더 낫설어졌다. □ 표시나 작은 칸은 영향이 없었다.

6.5 결론

- **픽셀 축은 달렸다.** 62,000장 증강 풀 설계가 맞았고, 1 에폭 79분이면 충분했다. 자동 중단 규칙이 남은 5 에폭(약 6.6시간)을 아꼈다.
- **실서식 축은 학습으로 안 풀리며, 2차로 오히려 멀어졌다.** 두 축은 독립이 아니다. 열화에 적응하는 비용을 실서식의 넓은 칸이 치렀다.
- **다음은 학습이 아니라 생성기다.** gp 투명 빈칸 폭을 40px에서 100px대까지, cgf 높이를 26px에서 41px대까지, cg 점유율 77%를 실서식 비율로. 척도 칸(opt)·원형 마커(circ)·이중 박스(dbx) 추가. 효과는 `diag_style.py --compare` 에서 cgf·cg·gp 세 줄로 바로 보인다.
- **3차는 처음부터 쉬는다.** 생성기를 고쳐 재렌더한 클린과 그 열화본을 한 풀로 학습하면, 이번처럼 한 축을 배우며 다른 축을 잃는 순서 효과를 피할 수 있다.
- **가중치 선택.** 실제 스캔 입력이 대상이면 `last_e1.pt(stress 99.9 / 실서식 59.6)`, 깨끗한 디지털 서식이 대상이면 1차 `best.pt(55.0 / 66.6)`. 둘 다 실서식 기준 미달이므로 임시 선택일 뿐이다.

stress의 열화와 학습 풀의 열화는 같은 생성기에서 나왔다. 99.94%는 "이 종류의 열화에 강하다"는 뜻이며 실제 스캔본으로 확인하기 전까지 일반화의 증명은 아니다.

부록 · 실행

```
yolo detect train model=/work/8_train/runs/ffdnet_1600/weights/best.pt
data=/work/8_train/forms_aug.yaml \
  imgs=1600 epochs=6 batch=4 device=0 fliplr=0 patience=3 project=/work/8_train/runs
name=ffdnet_1600_aug

# 에폭마다 (CPU)
python 8_train/score.py --model ../ffdnet_1600_aug/weights/best.pt --images
7_augment/pool/images/stress \
  --labels 7_augment/pool/labels/stress --name stress_eN --device cpu --chunk 16
python 8_train/score.py --model ... --images 8_train/yolo/images/replica --labels
8_train/yolo/labels/replica --name test_eN --device cpu

# 전후 비교 (스타일별, 실제 실행)
python 8_train/diag_style.py --compare 8_train/runs/score/style_replica_e6.json
8_train/runs/score/style_replica_aug_e1.json
```

산출물 (서버)

- 8_train/runs/ffdnet_1600_aug/weights/last_e1.pt — 최종 가중치 (203MB, 옵티마이저 상태 포함). 1차 가중치는 별도 디렉터리에 무손상.
- 8_train/runs/score/{fval,ftest,fstress}.json — 3축 채점.
rep_aug_c0.05/0.10 , rep_e6_c0.05/0.10 — 스윙.
- 8_train/runs/score/style_replica_{e6,aug_e1}.json — 스타일별 전후.
- 8_train/runs/val/{fuval,futest,fustress}/ — Ultralytics 표준,
confusion_matrix.png.

기준선 수치는 1차 학습 감사 보고서와 같다. 2차 데이터 정의는 8_train/forms_aug.yaml,
증강 축 정의는 7_augment/README.md.