

서식 검출기 세 라운드 결과

빈 행정서식에서 입력 칸을 찾는 검출기를 세 번 학습했습니다. 무엇을 바꿨고, 실제 서식에
서 얼마나 좋아졌고, 아직 못 찾는 칸은 왜 못 찾는지를 그림으로 정리했습니다.

실서식 44장 · 100칸 중 찾은 칸

84

1차 70 → 2차 63 → 3차 84 · 목표 98

찾은 칸의 종류를 맞춘 비율

97%

1차 59 → 3차 97 통과

찾은 칸의 위치 정확도

96%

1차 92 → 3차 96 통과

1. 세 라운드에서 무엇을 바꿨나

1차 · 의미 11종

실서식 70

깨끗한 합성 서식 2만 장. 칸의 뜻(이름·전화·체크박스...) 11종을 그대로 맞추게 함.

→ 합성은 만점, 실서식 70, 흐린 복사본 55

2차 · 11종 + 증강

실서식 63

1차 위에 복사기·스캔 열화 서식 6만 장을 더 가르침.

→ 흐린 복사본 99.9로 해결. 대신 실서식 넓은 셀을 잃음

3차 · 생김새 8종

실서식 84


검출기엔 모양만 묻고(□·낱칸·셀·빈칸·밑줄·자리표·서명·사진) 뜻은 2단계로. 생성기를 실서식 치수로 재구성. 클린+열화를 처음부터 한 풀로.

→ 종류 97, 위치 96, 복사본 99.9, 실서식 84

쉽게 말하면 1차는 "이 칸이 전화번호 칸인지"까지 그림만 보고 맞추라고 시켰습니다. 모양이 같은 칸(택일 □와 복수 □, 이름 칸과 전화 칸)은 그림에 답이 없어 틀렸습니다. 3차는 "어떻게 생겼나"만 묻고, 그 대신 연습 문제집을 실제 서식처럼 다시 만들었습니다. 그러자 종류 정확도가 59에서 97로 뛰었습니다.

2. 세 가지 시험, 세 라운드

시험은 셋입니다. 연습 문제집에서 뽑은 996장(합성), 실제 서식을 옮긴 44장(실서식), 홀드아웃에 복사기 열화를 입힌 500장(stress). 막대는 "100칸 중 맞은 칸".




실서식 44장 · 세 측	1차	2차	3차	기준
놓침 — 100칸 중 맞은 칸	69.6	63.4	83.9	98 미달
좌표 — 맞은 칸 중 위치 정확	91.9	94.3	96.2	95 통과
종류 — 맞은 칸 중 종류 정확	58.6	61.3	97.2	97 통과
Ultralytics mAP50	0.27	0.26	0.74	

3차는 세 측 중 둘을 처음 통과했습니다. 남은 것은 "찾기" 한 측입니다. 1·2차 실서식은 문턱 0.25·11종, 3차는 문턱 0.05·8종 기준입니다(같은 0.25로 맞추면 3차 80.8).

3. 어떤 모양의 칸을 잘 찾고, 못 찾나


3차 모델이 실서식에서 클래스별로 찾은 비율. 막대 색은 기준(95) 대비: 초록 계열은 도달, 노랑은 근접, 빨강은 미달.



읽는 법 테두리가 있거나 표시가 뚜렷한 것(날칸·밑줄·□)은 다 찾습니다. 못 찾는 것은 표시가 없는 빈칸(gap)과 인쇄 글자 위에 쓰는 자리표(placeholder), 그리고 셀의 일부입니다. 사진은 실서식에 2개뿐이라 1개 차이가 50%로 보입니다.


1차 → 3차, HTML 스타일별 변화

같은 실서식 칸을 "어떻게 그려졌나"로 나눈 것. 왼쪽 막대 1차, 오른쪽 막대 3차.



16종 중 15종이 좋아지거나 그대로이고, 내려간 것은 □ 마커 105개 중 1개뿐입니다. 1·2차에서 0%였던 척도 마커·원형·도장칸은 생성기에 그 부품을 넣은 뒤 100%가 됐습니다. "본 적 있으면 찾는다"는 것이 그대로 보입니다.

4. 3차 학습이 왜 3 에폭에서 멈췄나



세로축은 100칸 중 찾은 칸. 합성과 stress는 만점 근처에서 계속 오르고, 실서식은 1 에폭이 정점이고 내려갑니다. 예측 총수도 1,148 → 1,041로 줄었습니다.

쉽게 말하면 연습 문제를 더 풀수록 연습 문제집 점수는 오르는데 실전 점수는 내려갔습니다. 연습 문제집의 버릇(글자 없는 빈 칸, 넓은 빈칸)에 점점 더 맞춰지면서, 실전에서만 보이는 낮은 칸을 조심스럽게 안 찍기 시작한 겁니다. 그래서 "2 에폭 연속 1점 미만 상승이면 멈춘다"는 규칙이 3 에폭에서 발동했고, 가장 좋았던 1 에폭 모델을 최종으로 골랐습니다. 1차 때도 똑같은 모양이었습니다.

5. 못 찾은 16칸은 어떤 칸인가

놓친 칸 125개를 실제로 잘라, 연습 문제집에서 같은 크기의 칸과 나란히 놓고 비교했습니다. 두 가지 모양이 대부분을 차지합니다.

	매우만족	만족	보통	불만족	매우불만족
1. 서비스에 만족하십니까?	매우만족	만족	보통	불만족	매우불만족
2. 시간은 적절했습니까?	매우만족	만족	보통	불만족	매우불만족
3. 다시 이용하시겠습니까?	매우만족	만족	보통	불만족	매우불만족

① **글자가 인쇄된 척도 선택칸** — 놓친 셀 26개 중 25개. 사람이 글자 위에 ○를 치는 칸인데, 연습 문제집의 같은 크기 셀은 전부 글자 없는 빈 칸이었습니다. 모델은 "글자가 든 칸은 입력이 아니다"라고 배운 셈입니다.

20 년 월 일

실서식: 글자 사이 10~20px, 여백 없음

20 년 월 일

연습 문제집: 24~44px, 좌우 여백

② 날짜 글자 사이의 좁은 빈틈 — 놓친 빈칸 75개 중 69개가 높이 20px 이하이고, 폭 20px 이하 빈칸은 연습 문제집에 0개였습니다 (실서식 20개). 40~60px 빈칸도 실서식 44% 대 연습 14%로 적었습니다.

결론 "본 적 없는 것은 못 찾는다"입니다. 앞서 "같은 크기 칸이 연습에 수만 개 있다"고 봤지만 크기 구간이 너무 넓었고, 잘게 나누니 실서식에 있는데 연습에 없는 모양이 두 가지 드러났습니다.

6. 다음 라운드

보 강	무엇을	기대
①	글자가 인쇄된 척도 선택칸 카드(매우만족~매우불만족, 예/아니오, 해당/미해당)	놓친 cell 26 중 25 → cell 83 → 90대
②	날짜·기간 글자 사이 폭 10~20px 밀착 빈칸	학습 0 → 수천. gap 73 → 80대
③	폭 40~60px 빈칸 비중 14% → 40%대	gap 추가 회복
④	폭 60~90px 셀 비중 상향(현재 100~120에 몰림)	소형 셀 회복

같은 규칙으로 4차를 돌립니다. 1 에폭 결과(약 90분)에서 방향이 보이고, 정체 규칙이 조기 종료를 말합니다. 기록은 8_train/docs/PLAN.md 8절과 DECISIONS.md 9절에 있습니다.